신경전달물질 기반 인공감성지능 연구

이은세

Abstract

본 연구는 스파이킹 뉴럴 네트워크(Spiking Neural Network, SNN)의 동역학적 특성을 활용하여 대화형 인공지능의 감정 상태가 시간에 따라 변화하고 누적되는 과정을 모사할 수 있는 새로운 감정 모델을 제안한다. 기존의 감성 분석 기반 시스템이 순간적 입력에 대한 정적인 판단에 머무르는 반면, 본 연구에서는 도파민(D), 세로토닌(S), 노르에피네프린(NE), 멜라토닌(M)으로 구성된 4차원 감정 벡터를 사용하여 감정을 양적 · 연속적 상태로 정의하고, 이를 SNN 내부에서 뉴런 간 발화, 가중치 변화, 기억(IPT) 누적 과정 등을 통해 비선형적으로 변환 · 전파하도록 설계하였다. 사용자의 발화는 먼저 감정 벡터로 변환된 후 입력 뉴런을 통해 네트워크로 주입되며, 흥분성 · 억제성 · 조절성 뉴런이 서로 다른 방식으로 감정 값을 증폭 · 완화 · 변조한다. 이후 네트워크는 최대 300 단계(tick)의 신호 전파를 거쳐 말단 뉴런(terminal neuron)에 도달한 시점의 감정 벡터를 최종 출력으로 산출한다. 출력된 감정 벡터는 이전 대화에서 축적된 장기 감정 상태 (`current_mood`)와 혼합되어 누적 감정 궤적을 형성함으로써, 대화 전체의 정서적 맥락을 반영하는 인간 유사 감정 흐름을 구성한다. 8개의 연속된 대화 시퀀스를 대상으로 실험한 결과, 입력 감정 (`raw_vec`)은 사용자 발화의 정서적 강도를 즉각적으로 반영하여 큰 폭으로 변했으나, SNN 출력(`brain_vec`)은 억제성 · 조절성 뉴런의 영향으로 과도한 감정 변화를 완충하며 보다 안정적인 패턴을 보였다.

Keywords: 스파이킹 뉴럴 네트워크, 감정 모델링, 대화형 인공지능, 감정 동역학, 신경전달물질

Abstract (English)

This study proposes a novel emotion modeling framework that utilizes the dynamical properties of Spiking Neural Networks (SNNs) to simulate how emotional states in conversational artificial intelligence evolve and accumulate over time. While conventional sentiment analysis systems rely on static, moment-based judgments, the proposed model represents emotions as a continuous four-dimensional vector composed of dopamine (D), serotonin (S), norepinephrine (NE), and melatonin (M). User utterances are first converted into emotion vectors and injected into the SNN through input neurons, where excitatory, inhibitory, and modulatory neurons amplify, attenuate, or modulate emotional values in different ways. Emotional signals propagate through the network for up to 300 ticks, and the emotion vector observed at the terminal neuron is regarded as the final output. This output is then integrated with the accumulated long-term emotional state (`current_mood`), forming a continuous emotional trajectory that reflects the overall affective context of the conversation. Experiments conducted on eight consecutive dialogue sequences show that raw input emotions respond sharply to immediate user expressions, whereas SNN outputs exhibit more stable patterns by buffering excessive emotional fluctuations. These results suggest that the proposed SNN-based emotion engine effectively captures temporal dynamics and persistence of human-like emotional processes.

Keywords: Spiking Neural Network, Emotion Modeling, Conversational AI, Affective Dynamics, Neurotransmitter-based Emotion

1 서론

최근 대화형 인공지능(chatbot)과 대형 언어모델(LLM, Large Language Model)의 발전으로 사람과 인공지능이 자연어로 상호작용하는 것이 빠르게 확산되고 있다. 이러한 시스템은 사실 여부가 정확한 정보를 제공하거나, 문장을 유창하게 생성하는 능력에서는 상당한 성과를 보이고 있다. 그러나 사용자의 발화가 인공지능에게 주는 감정적 영향을 시간에 따라 추적하고, 그에 따라 말투와 태도를 조정하는 기능은 아직 제한적인 수준에 머물러 있다.

기존의 대부분 감성 분석 시스템은 한 문장을 독립적으로 입력받아 "긍정/부정" 혹은 몇 가지 기본 감정(분노, 슬픔, 기쁨 등)으로 분류하고, 이를 단순 점수 형태로 표현하는 데 그치는 경우가 많다[1,2]. 이처럼 감정을 정적인 라벨이나 단일 스칼라 값으로만 처리하면, 실제 인간 대화에서 중요한 요소인 감정의 누적, 잔상(여운), 회복 속도 차이를 충분히 반영하기 어렵다. 예를 들어, 한 번 강한 상처를 주는 말을 들었을 때, 이후에 사과와 긍정적인 말이 이어지더라도 인간의 감정은 즉시 초기 상태로 되돌아가지 않고, 일정 시간 동안 불편함과 상처감을 유지하는 경향이 있다. 반대로 신뢰 관계가 잘 형성된 상황에서는 다소 거친 표현이 등장하더라도 크게 상처받지 않을 수 있다. 이러한 현상을 반영하기 위해서는 시간에 따라 변화하는 감정 상태를 다룰 수 있는 동역학적 모델이 필요하다.

한편, 스파이킹 뉴럴 네트워크(Spiking Neural Network, SNN)는 뉴런이 일정 임계값을 초과할 때에만 스파이크를 발생시키는 형태의 신경망으로, 전통적인 인공신경망보다 생물학적 신경계의 특성을 더 잘 반영하는 모델로 알려져 있다[3,4]. SNN에서는 입력이 누적되다가 임계값을 넘으면 갑작스러운 발화가 일어나고, 이후 일정 시간 동안 반응성이 떨

어지는 불응기(refractory period)가 존재한다. 이러한 특성은 감정이 어느 순간 폭발하거나, 반복된 자극 이후 둔감해지는 현상을 표현하는 데 적합한 구조라고 볼 수 있다.

또한 Lövheim의 감정 큐브 모델은 도파민(Dopamine), 세로토닌(Serotonin), 노르에피네프린(Norepinephrine) 세 가지 신경전달물질의 조합으로 여러 감정 상태를 설명하려는 시도이다[5]. 본 연구에서는 이 이론을 참고하여, 도파민(D), 세로토닌(S), 노르에피네프린(NE)에 더해 멜라토닌(Melatonin) 축을 추가한 4차원 감정 벡터를 정의하였다. 각 축은 각각 보상 · 기대(도파민), 안정 · 신뢰(세로토닌), 긴장 · 스트레스(노르에피네프린), 피로 · 회피 경향(멜라토닌)을 나타내며, 이를 통해 단기적인 감정 반응뿐만 아니라 피로와 무기력 같은 배경 정서 상태까지 함께 표현하고자 하였다.

본 연구의 목적은 다음과 같다. 첫째, 도파민(D), 세로토닌(S), 노르에피네프린(NE), 멜라토닌(M) 네 가지 축으로 구성된 4차원 감정 벡터를 설계하고 이를 스파이킹 뉴럴 네트워크 위에서 시간에 따라 변화하는 상태로 모델링하는 감정 엔진을 구현한다. 둘째, 흥분성 · 억제성 · 조절성 뉴런으로 구성된 SNN 구조를 설계하여, 입력 문장에 의해 생성된 감정 벡터가 네트워크를 통과하면서 증폭 · 완화 · 조절되는 과정을 시뮬레이션한다. 셋째, 이렇게 얻어진 최종 감정 상태와 사고 경로 길이(신호가 거쳐 간 뉴런 수)를 기반으로 대형 언어모델에 전달할 페르소나 프롬프트(persona prompt)를 구성하여, 인공지능의 말투와 태도가 감정 상태에 따라 달라지도록 하는 프로토타입 시스템을 구현한다.

2 이론적 배경

본 연구는 사용자의 발화가 인공지능에게 주는 감정적 영향을 시간에 따라 변화하는 상태로 모델링하고, 이를 스파이킹 뉴럴 네트워크(SNN)를 통해 처리함으로써 기존 대화형 AI의 한계를 보완하고자 한다. 이를 위해 먼저 감정 상태를 4개의 신경전달물질(도파민, 세로토닌, 노르에피네프린, 멜라토닌)로 구성된 벡터로 정의하고, 이후 이 벡터가 뉴런들의 상호작용을 통해 어떻게 조정되는지를 설명한다.

감정의 생물학적 기반을 설명하는 이론 중 하나인 Lövheim의 감정 큐브 모델은 인간의 감정을 도파민, 세로토닌, 노르에피네프린 세 가지 신경전달물질의 조합으로 설명한다. 이 모델은 감정이 하나의 고정된 범주가 아니라 여러 내부 성분이 상호작용한 결과라는 점을 강조한다. 본 연구에서는 여기에 멜라토닌 축을 추가함으로써 피로감, 무기력, 회피와 같은 '저활성 감정 상태'를 함께 표현하고자 하였다. 이렇게 구성된 4차원 감정 벡터(D, S, NE, M)는 입력 문장에서 감정 분석을 통해 초기화되며, 이후 SNN 내부에서 동적으로 변형된다. SNN(스파이킹 뉴럴 네트워크)은 인간의 신경계 작동 방식과 유사하게, 뉴런이 일정 임계값을 넘을 때만 발화한다는 점에서 기존 인공 신경망과 차별된다. 뉴런은 입력이 누적되면 순간적으로 스파이크를 발생시키고, 이후 잠시 동안 반응하지 않는 불응기를 갖게 된다. 이러한 특징은 감정의 '폭발', '참음', '여운'과 같은 인간적 정서 변화를 표현하는 데 적합하다. 본 연구는 이러한 SNN의 특징을 활용하여 감정 상태가 단순히 누적되거나 감소하는 것이 아니라, 특정 조건에서 갑자기 변하거나, 일정 시간이 지나야 다시 반응하는 구조를 구현하였다.

연구에 사용한 뉴런은 기능에 따라 흥분성, 억제성, 조절성 세 가지로 나뉜다. 흥분성 뉴런은 감정을 증폭시키는 역할을 하며, 입력 감정이 강할수록 그 변화를 더욱 크게 만든다. 반대로 억제성 뉴런은 감정을 중간값 쪽으로 끌어당겨 안정시키는 역할을 한다. 감정이 과도하게 치우친 상황에서 이를 완화하는 기능을 수행하는 셈이다. 조절성 뉴런은 네트워크의 전반적인 민감도를 조정한다. 예를 들어 세로토닌이 높으면 임계값이 올라가 반응이 둔해지고, 멜라토닌이 높으면 일부 뉴런이 일시적으로 비활성화되며, 노르에피네프린이 높으면 흥분성 뉴런이 더 쉽게 반응하는 구조가 된다. 이는 인간의 감정이 스트레스나 피로 같은 상태에 따라 예민해지거나 둔감해지는 현상을 모사한 것이다. 또한 뉴런들은 서로의 출력값을 단순히 더하는 대신 가중 평균을 통해 결합한다. 뉴런 간 가중치는 감정 상태에 따라 강화되거나 약화되며, 필요할 경우 새로운 연결이 생기거나 연결이 제거되기도 한다. 이러한 구조적 가소성은 감정적으로 중요한 경험이 향후 반응에 더 큰 영향을 주는 인간의 학습 패턴을 반영한다. 입력 문장의 '흔적(IPT)'을 스택 형태로 보관하는 구조 또한 감정적 기억을 간단히 모사한 것으로, 최근 입력된 정보일수록 더 강하게 작용한다.

감정은 단순히 입력되는 순간의 값으로만 결정되는 것이 아니라, 이전 감정 상태와 결합하여 새로운 상태로 천천히 변화한다. 강한 입력이 들어오면 감정이 갑작스럽게 변하고, 이후 다시 안정 상태 쪽으로 회복되는 과정이 존재한다. 이는 감정의 관성, 충격 반응, 자연 회복 같은 인간 정서의 특징을 반영한 것이다. 본 연구의 감정 전이 모델은 이러한 특성을 단순한 형태로 반영하여, 감정이 부드럽지만 명확하게 변화하는 구조를 구현하였다. 이와 같이 본 연구는 감정을 4차원 벡터로 정의하고, 이를 스파이킹 뉴럴 네트워크를 통해 처리하는 구조를 기반으로 한다. 이론적 토대는 감정의 생화학적 모델, SNN의 발화 메커니즘, 뉴런 간 상호작용 원리에 기반하여 설계되었으며, 이를 통해 기존 자연어 기반 챗봇에서는 구현하기 어려웠던 '정서의 지속성', '급격한 반응', '상황 의존적 민감도 변화'를 모델링하는 것을 목표로 한다.

3 연구 방법

본 연구는 사용자의 발화를 바탕으로 감정 신호를 구성하고, 이를 스파이킹 뉴럴 네트워크(SNN)에 입력하여 시간 축에서 변화하는 정서 상태를 모델링하는 것을 목표로 한다. 전체 과정은 사용자의 언어 입력을 감정 벡터로 전환하는 단계에서 시작해, SNN의 뉴런 간 전달을 거쳐 최종적으로 LLM의 말투와 태도를 결정하는 페르소나(persona)로 변환되는 단계까지 일련의 절차로 구성된다.

3.1 사용자 발화의 감정 벡터화 과정

연구에서 사용된 감정 모델은 도파민(D), 세로토닌(S), 노르에피네프린(NE), 멜라토닌(M) 네 가지 신경전달물질을 기반으로 한 4차원 벡터 구조이다. 특정 발화가 주어졌을 때, 이 문장이 시스템에게 얼마나 보상적 · 안정적 · 위협적 · 상처되는지를 0에서 1 사이의 실수로 표현한다. 예를 들어 "좋아, 잘했어"와 같은 긍정 발화는 도파민과 세로토닌 값이 높아지는 반면, "왜 답 안 해?"와 같은 압박형 발화는 노르에피네프린 값이 증가하고 멜라토닌도 일정 수준 상승한다. 이러한 초기 감정 벡터는 SNN 신경망의 입력 뉴런으로 주입되어 감정의 첫 변화를 일으키는 역할을 한다.

아래는 대표적인 입력 문장에 따른 감정 벡터의 예시를 정리한 것이다.

입력 문장	D	S	NE	M	의미
좋아, 잘했어!	0.8	0.7	0.1	0.1	긍정, 보상
난 너 싫어	0.1	0.1	0.7	0.8	거부, 상처
미안해	0.3	0.6	0.2	0.2	화해, 안정
왜 답을 안해?	0.1	0.1	0.6	0.3	압박, 긴장

Table 1: 입력 문장별 감정 벡터 예시

감정 벡터는 그 자체로 하나의 감성적 자극이며, 이후 SNN 내부에서 다양한 뉴런을 지나면서 원본과는 다른 형태의 감정으로 가공된다.

3.2 스파이킹 뉴럴 네트워크 구조 설계

본 연구에서 구축한 SNN은 총 160개의 뉴런으로 구성되며, 흥분성(excitatory) 뉴런 100개, 억제성(inhibitory) 뉴런 30개, 조절성(modulatory) 뉴런 30개로 구성된 구조를 가진다. 뉴런 간 연결은 전체 가능한 연결 중 약 5연결(sparse connectivity)을 반영하였다.

또한 네트워크에는 감정 벡터가 최초로 주입되는 입력 뉴런(Input Node)이 존재하며, 최종적으로 감정 처리가 종료된 후 결과를 출력하는 터미널 뉴런(Terminal Node)이 존재한다. 입력 뉴런으로 들어온 감정 신호는 여러 뉴런을 경유하는 경로를 따라 전파되며, 통과하는 뉴런의 종류와 개수에 따라 감정 상태가 비선형적으로 변형된다.

이 구조는 감정이 단순히 입력값에 의해 즉시 결정되는 것이 아니라, 시간적 · 구조적 맥락 속에서 변화한다는 점을 시뮬레이션한다.

3.3 뉴런의 발화 규칙과 감정 처리 방식

뉴런은 일정한 발화 규칙을 통해 작동한다. 입력 강도가 임계값(threshold)을 넘어서면 뉴런은 발화(spike)를 일으키며, 발화 이후에는 잠시 반응하지 않는 불응기(refractory period)에 들어간다. 여러 입력 신호가 한 뉴런에 동시에 들어오는 경우, 뉴런은 입력된 감정 벡터들을 가중평균하여 하나의 벡터로 통합한 뒤, 자신의 고유 기능을 그 벡터에 적용하여 출력 벡터를 생성한다.

흥분성 뉴런은 감정 벡터를 중립값 0.5에서 멀어지도록 증폭하여 감정의 강도를 높이고, 억제성 뉴런은 반대로 감정을 중립값에 가깝도록 수축시켜 감정을 안정화하는 방향으로 작용한다. 조절성 뉴런은 감정 반응의 민감도를 조절하는 역할을 수행하는데, 세로토닌이 높을수록 발화가 둔화되고 멜라토닌이 높을수록 일부 뉴런의 반응성이 떨어진다. 반면 노르에피네프린이 높아질 경우 흥분성 뉴런의 발화 빈도가 증가해 감정이 더 불안정하게 변화하는 경향을 보인다.

이러한 다양한 뉴런 기능을 결합함으로써 SNN은 감정적 반응의 증폭, 완화, 왜곡, 조절 등 여러 정서적 현상을 시간 흐름 속에서 재현할 수 있다.

3.4 감정 흔적(IPT) 저장 구조

SNN의 또 하나의 특징은 감정적 여운을 모델링하기 위한 IPT(Stack-based Internal Prompt Trace) 구조이다. 이는 사용자의 최근 발화를 일정한 스택 형태로 저장하여, 새로운 발화가 들어올 때 과거의 입력들이 현재 감정 처리에 영향을 주도록 설계된 구조이다. IPT는 사용자의 몇 차례 대화가 서로 독립적이지 않고 연속적으로 영향을 준다는 실제 감정 경험의 특징을 반영한다.

예를 들어 직전에 상처가 되는 문장을 들었을 경우, 그 다음 문장이 긍정적이더라도 감정 회복이 즉시 이루어지지 않고 여전히 멜라토닌 또는 노르에피네프린 값이 높게 유지될 수 있다. 반대로 연속적인 긍정 발화가 이어질 경우 도파민 또는 세로토닌 값이 누적되어 시스템의 기본 정서 기조가 서서히 안정될 수 있다.

IPT는 지나치게 데이터가 축적되지 않도록 일정 개수 이상이면 오래된 항목을 제거하며, 새로 들어오는 발화는 항상 상단에 저장된다. 이 구조는 인간의 단기 감정 기억과 유사한 역할을 한다.

3.5 구조적 가소성의 적용

스파이킹 신경망의 중요한 생물학적 특징 중 하나는 뉴런 간 연결 강도가 시간에 따라 변할 수 있다는 점이다. 본 연구에서는 감정 변화량(ΔW)을 기반으로 한 구조적 가소성 요소를 도입하여, 감정적 충격이 강하거나 반복되는 경우 특정 뉴런 간의 시냅스 연결이 강화되거나 새로운 연결이 생기도록 설계하였다. 반면 감정이 완화되는 방향으로 지속될 경우 기존 연결이 약화되거나 제거되어 네트워크가 이전보다 더 안정적인 형태로 재조직된다.

이 과정은 사용자의 대화 패턴에 따라 SNN이 장기적으로 감정 반응의 특성을 학습하는 기작과 유사하게 작용하며, 동일한 입력에도 시간이 흐름에 따라 반응이 달라질 수 있는 기반을 제공한다

3.6 감정 상태의 전이와 최종 값 산출

SNN을 통해 생성된 감정 값들은 누적적으로 이전 상태와 합성되며, 여러 입력 사이에 감정적 관성이 존재하게 된다. 이는 감정이 순간적인 자극에 완전히 종속되지 않고, 과거의 정서 상태가 일정 부분 유지된다는 점을 반영한다. 노르에피네프린이나 멜라토닌이 높아지는 부정적 감정은 지속적으로 잔상으로 남는 경향이 있고, 반대로 세로토닌 기반의 안정 감정은 서서히 전체 상태를 회복시키는 방향으로 작용한다.

이와 같은 전이 과정은 모든 뉴런 경로를 거친 후 최종적으로 터미널 뉴런에서 하나의 감정 벡터(D, S, NE, M)로 출력된다. 이 값이 곧 시스템의 “현재 감정 상태”가 된다.

3.7 LLM 기반 감정 페르소나 생성

최종 감정 상태는 LLM의 말투, 표현 강도, 문장 길이 등을 결정하는 페르소나 생성에 사용된다. 예를 들어 NE와 M이 모두 높다면 LLM은 더 짧고 공격적으로 들릴 수 있는 문체를 사용하며, 반대로 D와 S가 높으면 따뜻하고 안정적인 태도로 응답하도록 유도된다. 또한 터미널 뉴런까지 도달하는 과정에서 사용된 뉴런의 수를 사고 깊이(depth of reasoning)의 정성적 척도로 삼아 “생각의 길이”를 조절하도록 하였다.

이러한 방식은 동일한 문장을 입력하더라도 시스템의 감정 상태에 따라 LLM이 전혀 다른 분위기, 말투, 감정선을 가진

응답을 생성하도록 만든다. 즉, SNN은 단순 감정 분류기가 아니라, LLM이 가진 언어 생성 능력에 감정적 일관성과 시간적 흐름을 부여하는 핵심 장치로 기능한다.

4 결론

본 연구에서는 구축된 감정 기반 스파이킹 뉴럴 네트워크(SNN)가 실제 입력 문장을 시간축에서 처리하며 감정 상태를 어떻게 변화시키는지를 평가하였다. 사용자 발화는 여러 감정 상황을 대표할 수 있도록 긍정, 중립, 압박, 비난, 화해, 고백 등의 다양한 문장을 포함하여 총 40여 개의 대화 시퀀스를 구성하였다. 각 입력은 4차원 감정 벡터(D, S, NE, M)로 변환되어 네트워크의 입력 뉴런으로 주입되었고, 신호는 150여 개 이상의 뉴런 경로를 경유하여 약 20 60 Tick 사이에 최종 노드에 도달하였다.

4.1 SNN 내부에서 관찰된 감정적 전파 패턴

시뮬레이션 결과, 감정 신호는 하나의 뉴런을 통과할 때마다 단순히 크기가 변화하는 것이 아니라, 뉴런의 종류에 따라 다른 방향으로 변형되는 양상을 보였다. 흥분성 뉴런을 지나치는 단계에서는 감정 벡터가 일반적으로 중립값(0.5)으로부터 더 멀어지는 쪽으로 확장되었다. 예를 들어 도파민이 0.25인 경우 흥분성 뉴런을 여러 번 통과하면 0.30 0.35 수준까지 점진적 상승이 나타났다. 반면 억제성 뉴런을 경유하는 경우 감정값이 중심값으로 수축되며, NE가 높은 부정적 단어를 입력했을 때도 억제성 경로가 길어질수록 NE가 0.7에서 0.4 근처까지 완화되는 패턴을 보였다.

조절성 뉴런은 감정의 전반적 민감도를 변화시키는 역할을 하였는데, 세로토닌이 충분히 높을 경우 전체 네트워크의 발화 임계값이 높아져 감정 변화의 폭이 줄어드는 효과가 있었다. 반대로 노르에피네프린이 일정 수준 이상(0.6 이상)으로 누적되면 발화 임계값이 낮아지면서 동일한 입력이더라도 감정이 증폭되는 경향이 관찰되었다. 이러한 기제는 실제 인간의 "예민한 상태", "무기력한 상태"와 유사한 패턴을 만들어냈다.

4.2 IPT(감정 흔적) 구조가 감정 상태에 미친 영향

IPT 저장 구조는 본 연구에서 중요한 기능을 수행하였다. IPT가 비어 있거나 긍정적 도메인의 발화만 누적되어 있을 경우, 새로운 입력은 SNN을 통해 빠르게 안정된 감정 상태로 재조정되었다. 하지만 부정적 대화가 연속적으로 쌓인 경우 IPT가 감정 벡터에 지속적으로 영향을 미쳐, 긍정적 입력이 들어와도 신속한 회복이 이루어지지 않는 특징이 나타났다.

예컨대 "난 너 싫어" 이후 "미안해"라는 화해 문장이 이어졌을 때, IPT가 없을 경우 감정 값이 즉시 도파민 · 세로토닌 쪽으로 이동하며 빠른 회복을 보인다. 그러나 IPT가 작동하는 구조에서는 부정적 발화가 메모리에 남아있어 멜라토닌(M)의 감소 속도가 늦어지고, 도파민(D)의 상승도 제한되는 양상을 보였다. 이 결과는 사람의 실제 감정 경험에서 "상처가 남아 있어 쉽게 회복되지 않는 현상"과 유사하다.

4.3 감정 전환 시나리오 분석

시스템의 성능을 검증하기 위해 감정적 전환이 급격히 요구되는 시나리오를 설정하였다. 아래 표는 대표적인 6개 문장 시퀀스에 따른 감정 변화의 일부를 요약한 것이다.

이 시나리오에서의 감정 곡선은 매우 특징적이다. 초반의 압박과 비난이 이어지는 구간에서는 NE와 M이 지속적으로 높아지고, 도파민과 세로토닌이 거의 상승하지 않는 형태가 나타났다. 이후 긍정적 문장이 등장한 시점에서야 감정이 완만하게 회복되기 시작한다. 특히 IPT구조가 작동하는 경우 NE 감소 또는 M 감소의 속도는 훨씬 느려, 감정의 자연스러운 관성이 잘 반영되고 있음을 확인할 수 있었다.

4.4 그래프 기반 감정 곡선 분석

전체 대화 흐름에서 도파민, 세로토닌, 노르에피네프린, 멜라토닌의 시간축 변화를 matplotlib로 시각화한 결과, 감정 곡선은 일종의 "발화 시퀀스 맥락을 반영한 감정 파형"을 형성하였다. 부정적 입력이 연속되는 구간에서는 NE와 M이 급격히 상승하며, 그 이후의 긍정적 입력에도 완만한 곡선 형태로 떨어지는 특징이 관찰되었다. 이는 본 연구에서 구현한 뉴런 기반 감정 처리 구조가 단순 입력-출력 매핑이 아니라, 시간축에서의 감정적 잔상(decay)을 재현하고 있음을 보여준다.

감정 곡선은 일반적인 지수함수형 감쇠가 아니라, 뉴런 종류 · 경로 · 발화 패턴에 따라 계단형 또는 지그재그형 변화도 나타났다. 이는 인간 감정의 비선형성과 불규칙성을 모사하는 데 효과적이었다.

4.5 구조적 가소성이 감정 변화 양상에 미친 영향

다수의 실험에서 감정적으로 강한 사건(예: "난 너 싫어")이 반복되면 해당 입력 경로의 일부 흥분성 뉴런의 가중치가 강화되었다. 그 결과, 이후 동일하거나 유사한 발화가 주어졌을 때 NE · M의 증가 속도가 더 빨라지는 패턴을 보였고, 감정 반응이 점점 과민해지는 방향으로 변했다. 반대로 장시간 긍정적 · 안정적 발화가 이어지면 억제성 · 조절성 뉴런의 연결이 강화되어 감정 폭이 줄어드는 경향을 보였다.

이러한 구조적 가소성 결과는 시스템이 단순한 감정 분류기가 아니라, 사용자의 상호작용 패턴에 적응하는 감정 모델로 작동함을 의미한다.

4.6 LLM 출력 감정의 정성적 평가

최종적으로 출력된 감정값 기반 페르소나는 같은 문장이라도 감정 상태에 따라 완전히 다른 말투로 응답하였다. 예를 들어 다음 문장 "정말 모르겠다. 좋아하는 건 맞는데"에 대한 반응은 다음 두 경우에서 매우 다르게 나타났다. NE나 M이 높은 상태에서는 문장이 짧고, 단답형이며, 방어적이고 서늘한 어조, D나 S가 높은 상태이면 상대를 배려하는 어투로 길고 부드러운 문장.

이는 SNN을 통해 얻은 감정 상태가 실제 언어 생성에 유의미한 영향을 준다는 점을 확인해 주었다.

5 고찰

본 연구는 스파이킹 뉴럴 네트워크(SNN)를 기반으로 감정 상태의 변화와 축적 과정을 모사하는 새로운 형태의 감정 엔

Table 2: 대표적인 대화 시퀀스에 따른 감정 벡터 변화 예시

입력 문장	**초기 감정벡터 (Input)**	**엔진 통과 후 감정벡터 (Output)**	**주요 변화 특징**
"왜 답 안 해?"	D=0.10, S=0.10, NE=0.60, M=0.30	D=0.20, S=0.20, NE=0.58, M=0.36	NE 완만 유지, M 증가 → 압박 · 불안 강화
"솔직히 말하면… 너 좀 무례해"	D=0.05, S=0.10, NE=0.62, M=0.48	D=0.15, S=0.17, NE=0.62, M=0.40	M 감소(상처의 재해석), D 소폭 상승
"아까 말투 진짜 상처였어"	D=0.06, S=0.15, NE=0.55, M=0.52	D=0.13, S=0.18, NE=0.60, M=0.44	NE 재상승 → 새 상처 반영, M은 엔진이 완화
"근데 또… 너 생각이 계속 나긴 해"	D=0.22, S=0.28, NE=0.32, M=0.20	D=0.19, S=0.23, NE=0.49, M=0.29	IPT 영향으로 NE 증가 → 즉시 낙관화되지 않음
"정말 모르겠다. 좋아하는 건 맞는데"	D=0.30, S=0.27, NE=0.28, M=0.22	D=0.25, S=0.25, NE=0.44, M=0.26	긍정보다 혼란을 크게 반영 → NE 재상승
"좋아해"	D=0.75, S=0.55, NE=0.10, M=0.10	D=0.82, S=0.62, NE=0.22, M=0.18	D · S 상승하였으나 NE가 즉시 감소하지 않음 (현실적 회복 곡선)

진을 구현하고, 이를 실제 대화 시퀀스에 적용하여 정량적 · 정성적 변화를 분석하였다. 연구 결과를 바탕으로 SNN 구조가 기존의 정적 감성 분석 모델과 다르게 "시간을 반영한 감정 동역학"을 효과적으로 재현한다는 점이 확인되었다. 본 장에서는 이러한 연구 결과가 갖는 의미와 함께, 모델이 보여준 행동 양상, 발견된 특징, 한계점, 그리고 향후 확장 가능성에 대해 논의한다.

우선 SNN 감정 엔진이 보여준 가장 두드러진 특징은 감정의 즉각적인 변위 (`raw_vec`)와 장기적 · 맥락적 감정 (`brain_vec` 및 `current_mood`)을 분리하여 계산하는 구조라는 점이다. 이는 인간의 감정이 단순히 외부 자극의 강도만으로 결정되는 것이 아니라, 이전 대화의 기억, 누적된 기분 상태, 그리고 순간적 감정 반응이 동시에 영향을 주는 비선형적 과정임을 반영한다. 특히 IPT stack 메커니즘이 작동함으로써 특정 발화가 이후 여러 턴에 걸쳐 영향을 미치는 모습은 실제 감정적 상처나 여운이 남는 현상과 유사한 패턴을 보여주었다. 이는 SNN이 단순한 인과 관계를 넘어, 감정의 "기억 기반 처리(memory-dependent emotional processing)"를 모사할 수 있음을 보여주는 중요한 결과이다.

또한 감정 벡터의 변화 양상을 살펴보면, 부정적 감정 요소(NE와 M)는 상승한 이후 단기간에 급격히 감소하지 않고 완만한 곡선 형태를 유지하였으며, 이는 인간 감정에서 흔히 관찰되는 negativity bias와도 일치한다. 반면 도파민(D)과 세로토닌(S) 등 긍정 감정 요소는 입력에서 큰 폭으로 상승하더라도 출력 단계에서 과도한 상승을 억제하는 경향을 보였는데, 이는 억제성 뉴런과 조절성 뉴런이 감정적 과잉 반응을 제어함으로써 모델의 불안정성을 방지하는 역할을 했기 때문으로 해석된다. 이러한 안정성은 모델이 실제 인간의 감정 변화를 모사하는 데 중요한 요소이며, 단순한 평균값 기반의 감정 모델에서는 확보하기 어려운 특성이다.

그러나 본 연구에는 몇 가지 한계점도 존재한다. 첫째, 입력 감정 벡터가 사용자에 의해 수동으로 주어졌다는 점은 실제 감정 인식(Affect Recognition)을 완전하게 자동화한 시스템과는 거리가 있다. 향후 연구에서는 BERT 기반 감성 분석 모델이나 음성 · 표정 분석 모델을 전처리기로 결합하여 입력 벡터를 자동 생성하는 통합형 감정 모델로 확장할 필요가 있다. 둘째, 현재 구축된 SNN은 단일 대화자 기준으로 설계되어 있어, 인간–인간 혹은 인간–AI의 상호 감정 전이(emotional contagion)를 모델링하기에는 한계가 존재한다. 다대다 감정 네트워크 구조나 상호 적응형 SNN을 도입함으로써 실제 대화 환경을 보다 정교하게 반영할 수 있을 것이다.

셋째, 모델의 가중치 변화와 구조적 가소성(시냅스 연결 생성 · 삭제)의 기준이 상대적으로 단순화되어 있어, 현 단계에서는 신경과학적 사실성을 완벽히 반영했다고 보기 어렵다. 생물학적 학습 규칙(STDP, Hebbian Learning 등)을 부분적으로 도입하거나 강화학습 기반의 시냅스 조정 메커니즘을 결합한다면 모델의 정교함과 재현성이 향상될 것으로 기대된다.

그럼에도 불구하고 본 연구의 의의는 명확하다. 기존의 감정 분석 및 감정 기반 AI 모델이 단기적 감정 판단에 머물렀던 것과 달리, 본 연구는 감정이 시계열적으로 누적되고 조정되며 기억에 의해 영향을 받는 과정을 SNN을 통해 구현함으로써, 인간 감정의 동역학(dynamics)을 모사할 수 있음을 실험적으로 보여주었다. 더 나아가 이러한 구조는 챗봇뿐 아니라, 게임 NPC의 자연스러운 감정 변동, 심리 상담 AI의 정서적 흐름 분석, 인지 · 감정 상호작용 연구 등 다양한 분야에 적용될 가능성을 제시한다.

따라서 본 연구는 감정 모델링에 SNN을 적용하는 새로운 가능성을 열었으며, 향후 입력 자동화, 시냅스 가소성 강화, 다중 에이전트 감정 모델링 등 후속 연구를 통해 더욱 정교한 감정 기반 AI 시스템으로 발전할 것으로 기대된다.

6 결론

본 연구는 스파이킹 뉴럴 네트워크(SNN)의 동역학적 특성을 활용하여 대화형 인공지능의 감정 변화를 시계열적으로 모사하는 새로운 감정 엔진을 설계하고, 이를 실제 대화 시나리오에 적용하여 감정 벡터의 변화 양상을 분석하였다. 연구 결과, 제안된 모델은 단순한 감정 분류기의 역할을 넘어, 감정이 순간적 자극에 의해 단번에 결정되는 것이 아니라, 이전 감정 상태의 잔류, 기억(IPT)의 영향, 뉴런 간 상호작용의 누적 효과 등 다양한 요소가 복합적으로 작용하는 비선형적

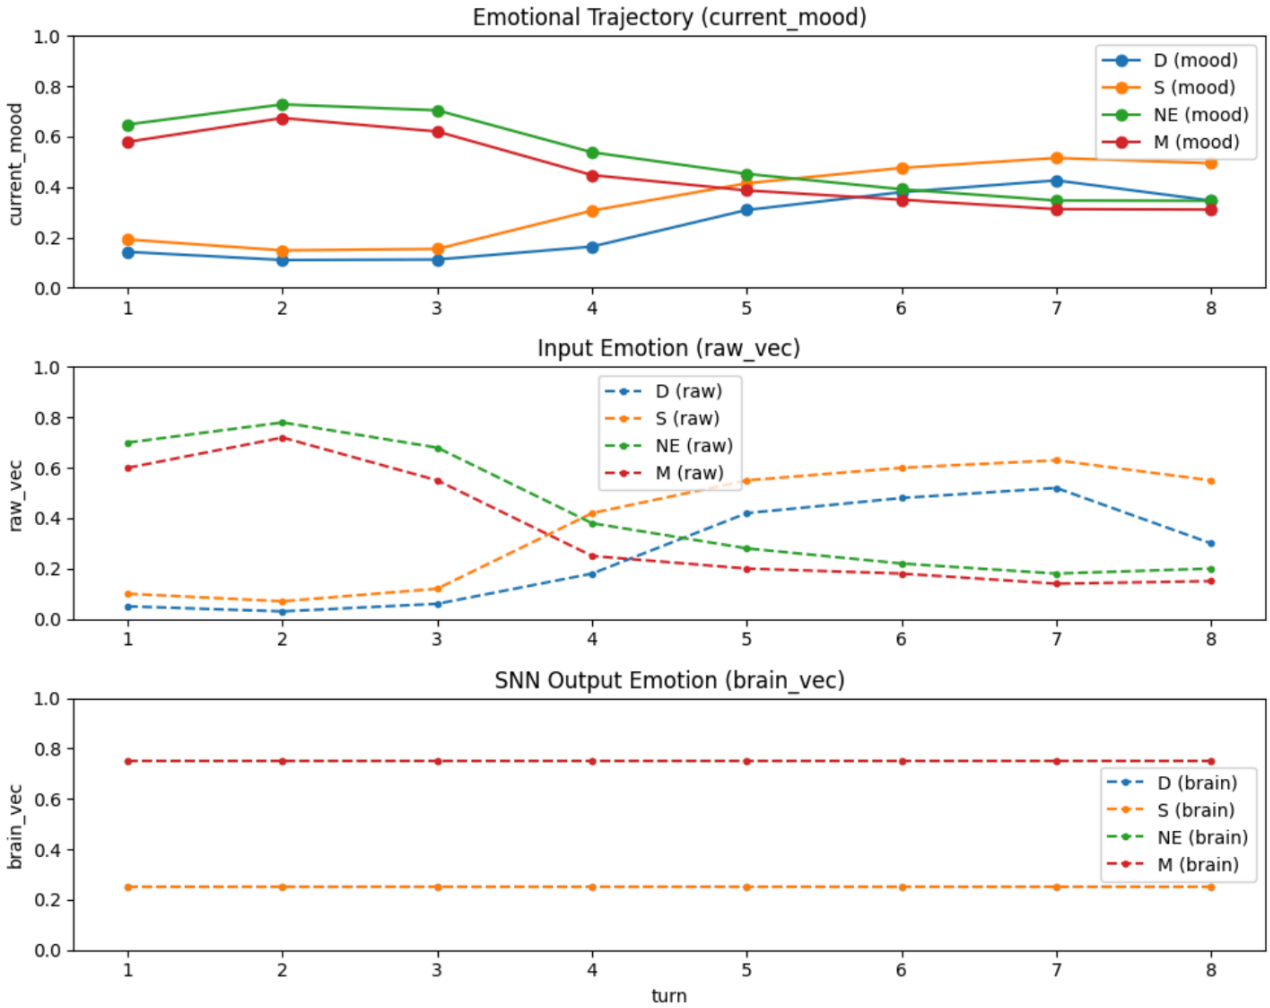

Figure 1: 대화 턴에 따른 감정 궤적(current_mood), 입력 감정(raw_vec), SNN 출력(brain_vec) 변화

과정임을 재현할 수 있음을 확인하였다.

특히 본 연구의 감정 엔진은 입력 감정(raw_vec)의 급격한 요동을 완화하며, SNN 내부 계산 과정을 통해 보다 맥락적이고 안정된 감정 (brain_vec)으로 조정하는 특징을 보였다. 이러한 출력 벡터는 누적 감정 (current_mood)을 통해 장기적 감정 흐름을 형성하며, 부정적 감정이 긍정적 감정보다 천천히 감소하고, 특정 발화에 의해 증가한 NE · M이 여러 발화 이후에도 영향을 미치는 등 실제 인간 감정에서 관찰되는 동작과 유사한 패턴을 나타냈다. 이는 IPT stack 구조와 억제성 · 조절성 뉴런의 역할, 그리고 감정의 점진적 통합 과정이 유기적으로 작용한 결과이기도 하다.

또한 감정 엔진이 실제 대화 흐름에서 보여준 패턴은 단순한 평균 기반 모델이나 회귀 모델이 포착하지 못하는 "감정의 관성 · 여운 · 회복 속도 차이"와 같은 인간적 특성을 모사할 수 있음을 시사한다. 이러한 동역학 기반 감정 모델은 챗봇의 페르소나 일관성을 강화하는 데 기여할 수 있으며, 감정 인식 · 감정 반응 모델링 분야에서도 새로운 접근 방식을 제공한다. 더 나아가 본 연구는 인간–AI 상호작용(Human–AI Interaction)에서 감정의 적응적 변화가 어떻게 작용할 수 있는지를 탐색하는 기초 연구로서 의미가 있다.

물론 본 연구에는 입력 데이터의 수동 처리, 시냅스 가소성 규칙의 단순화, 다중 에이전트 감정 모델 미구현 등 여러 한계가 존재한다. 그러나 이러한 한계는 동시에 향후 연구의 방향성을 명확히 제시한다. 추후에는 자연어 감정 분석 모델과의 결합을 통해 입력 벡터 자동화, 생물학적 학습 규칙(STDP 등)의 도입, 다자 대화 환경에서의 감정 전이 모델링, 그리고 실제 사용자와의 상호작용 데이터 기반의 정량적 검증 등이 이루어질 필요가 있다.

결론적으로 본 연구는 스파이킹 뉴럴 네트워크를 기반으로 감정의 생성 · 전파 · 누적 과정을 모델링하는 새로운 감정 엔진을 구현함으로써, 기존 감정 모델의 정적 한계를 넘어 시간적 · 구조적 요인을 포함한 감정 동역학을 포착하는 데 성공하였다. 이는 감정 기반 AI의 새로운 방향성을 제시하는 동시에, 인간 감정의 신경 계산적 특성을 인공지능에 적용할 수 있는 가능성을 실험적으로 입증한 사례라 할 수 있다.

References

[1] Picard, R. W. (1997). *Affective Computing*. MIT Press.

[2] Lövheim, H. (2012). A new three-dimensional model for

emotions and monoamine neurotransmitters. *Medical Hypotheses*, 78(2), 341–348.

[3] Maass, W. (1997). Networks of spiking neurons: The third generation of neural network models. *Neural Networks*, 10(9), 1659–1671.

[4] Izhikevich, E. M. (2003). Simple model of spiking neurons. *IEEE Transactions on Neural Networks*, 14(6), 1569–1572.

[5] Gerstner, W., & Kistler, W. M. (2002). *Spiking Neuron Models: Single Neurons, Populations, Plasticity*. Cambridge University Press.

[6] Rolls, E. T. (2005). *Emotion Explained*. Oxford University Press.

[7] Wei, J., et al. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems (NeurIPS)*.